

Clustering Analysis of time-step cell enzyme interactions

Karol Chądzyński, Paweł Galek

19 maja 2026

1 Część A

1.1 Zadanie A1

"Czy różne mutacje w szlaku PI3K-AKT wpływają na siłę czasoprzestrzennej propagacji sygnału? "


Na początku odpaliliśmy zmodyfikowany skrypt "*compare-spatiotemporal-behavior.py*" używając domyślnych parametrów aby otrzymać dane dotyczące propagacji sygnału dla każdego z mutantów.

Następnie dla każdej wariancji obliczyliśmy jego metryki, w tym p-wartość względem wariantu dzikiego, które umieściliśmy w następującej tabelce:

	mutant	statistic	RR_mean	standard_error	p_value	significant
0	AKT1_E17K	381.0	1.581421	0.071932	3.461467e-03	True
1	PIK3CA_E545K	353.0	1.707110	0.031885	1.835290e-01	False
2	PIK3CA_H1047R	0.0	3.200310	0.130643	3.063664e-09	True
3	PTEN_del	594.0	1.556633	0.021624	3.660584e-07	True

Rysunek 1: Tabela porównawcza

Zanim wykonaliśmy test statystyczny Mann-Whitney'a zastosowaliśmy korektę Bonferroniego aby obniżyć ryzyko fałszywych pozytywów. Na podstawie danych otrzymanych powyżej narysowaliśmy ten wykres słupkowy ilustrujący średnią wartość względnego ryzyka z uwzględnieniem istotności:



Rysunek 2: Wykres słupkowy

Interpretacja:

Wyniki uzyskane dla poszczególnych mutantów porównano z wariantem dzikim (WT), dla którego wartość RR_{mean} wynosiła ok. 1,7423, co oznacza wzrost szansy na reakcję o 74,23%. Dla mutantów *PIK3CA_H1047R*, *AKT1_E17K* oraz *PTEN_del* odnotowano zmiany istotne statystycznie. W przypadku wariantu *PIK3CA_E545K* nie zaobserwowano istotnych różnic względem typu dzikiego.

Szczegółowa charakterystyka badanych wariantów:

PIK3CA_H1047R — W tej grupie zaobserwowano najsilniejsze zmiany spośród wszystkich analizowanych wariantów. Wartość RR_{mean} wzrosła prawie dwukrotnie. Statystyki dla tego mutantu prezentują się następująco:

- $RR_{\text{mean}} = 3,200310$,
- błąd standardowy (*standard error*) = 0,130643,
- $p < 0,001$.

AKT1_E17K* oraz *PTEN_del — U obu mutantów odnotowano niewielki, lecz statystycznie istotny spadek wartości RR_{mean} w porównaniu do wariantu dzikiego:

- RR_{mean} odpowiednio: 1,581421 oraz 1,556633,
- błąd standardowy (*standard error*) odpowiednio: 0,071932 oraz 0,021624,
- $p < 0,01$.

PIK3CA_E545K — Nie wykazano istotnych zmian statystycznych. Na tej podstawie należy wnioskować, że obecność tej konkretnej mutacji nie wpływa na koordynację sygnału w szlaku ERK.

Dyskusja i wnioski:

Drastyczny wzrost wskaźnika RR_{mean} u mutantu *PIK3CA_H1047R* sugeruje, że mutacja ta silnie promuje produkcję oraz wydzielanie czynników sygnałowych odpowiedzialnych za rozprzestrzenianie się fal aktywności ERK. Równie prawdopodobnym wyjaśnieniem tego zjawiska jest znaczne uwrażliwienie komórek docelowych na sygnały parakryne pochodzące od komórek sąsiadujących.

Natomiast obniżenie poziomu RR_{mean} u mutantów *AKT1_E17K* oraz *PTEN_del* można tłumaczyć stale podwyższoną, bazową aktywnością konstytutywną szlaku. Konsekwencją takiego stanu jest zmniejszona podatność komórek na bodźce i sygnały docierające ze środowiska zewnętrznego.

1.2 Zadanie A2

"Czy różne mutacje wykazują odmienne skale czasowe czasoprzestrzennego przekazywania sygnału (jak szybko aktywacja propaguje się od sąsiada do komórki ogniskowej ")

Zdecydowaliśmy porównać *PIK3CA-H1047R* oraz *PIK3CA-E545K*, ponieważ chcieliśmy porównać jak dwie różne mutacje tego samego genu (które dodatkowo zupełnie inaczej wpływają na wartość relatywnego ryzyka co wykazano w zadaniu A1) różnią się, bądź jak bardzo są podobne.


Po zmodyfikowaniu notatnika "*Part2 - L1 - LaggedExposure.ipynb*" otrzymaliśmy następujące wyniki:

	Mutant	τ (frames)	τ (min)	RR
7	PIK3CA_E545K	0	0	1.6264
14	PIK3CA_H1047R	0	0	2.8435
0	WT	0	0	1.7558

Rysunek 3: Tabela podsumowująca wymagana w zadaniu

Interpretacja:

Jak wynika z przedstawionego wykresu, maksymalna wartość ryzyka względnego (RR) osiągana jest dla wszystkich badanych wariantów w punkcie czasowym $t = 0$. W miarę upływu czasu wartość tej metryki sukcesywnie maleje.




Rysunek 4: Wykres ukazujący stosunek RR do τ dla wariantu dzikiego i dwóch wybranych mutantów

1. **Wariant *PIK3CA_H1047R*** — Wykazuje silną hiperaktywację oraz znacznie gwałtowniejszy spadek wartości RR w czasie w porównaniu do typu dzikiego (WT) oraz wariantu *PIK3CA_E545K*. Zjawisko to można tłumaczyć wzmożonym działaniem komórkowych mechanizmów regulacyjnych opartych na ujemnym sprzężeniu zwrotnym.
2. **Wariant dziki (WT) oraz mutant *PIK3CA_E545K*** — Cechują się bardzo zbliżonym przebiegiem krzywej zmian RR w funkcji czasu. Jediną wyraźną różnicą jest fakt, że wariant dziki systematycznie osiąga nieco wyższe wartości tej metryki.

1.3 Zadanie A3

Jak wrażliwy jest wskaźnik ryzyka względnego na dobór parametrów analizy?

Zdecydowaliśmy się wybrać parametr r - czyli promień koła, w obszarze którego bierzemy pod uwagę sygnał w naszej analizie. Po wygenerowaniu kodem z zajęć - "*Part1-Block2-ParameterSensitivity.ipynb*" danych dla różnych wartości parametru, stworzyliśmy następujący wykres:



Rysunek 5: Wykres ukazujący stosunek RR do parametru

Interpretacja i rekomendacja:

Zgodnie z oczekiwaniami teoretycznymi, wartość ryzyka względnego wykazuje zależność odwrotnie proporcjonalną do promienia przestrzennego. Im mniejsza odległość dzieli komórkę ogniskową od komórek otaczających, tym silniejsza jest korelacja ich aktywacji, co manifestuje się wyraźnym wzrostem wskaźnika RR .

1. **Przedział wartości skrajnie niskich (do 30):** W tym obszarze obserwowany jest gwałtowny spadek wartości RR . Z biologicznego punktu widzenia, zbyt drastyczne zawężenie promienia odcięcia ogranicza liczbę analizowanych sąsiadów. Prowadzi to do sytuacji, w której lokalny szum oraz fluktuacje pojedynczych komórek zaczynają dominować nad realnym sygnałem biologicznym.
2. **Przedział wartości skrajnie wysokich (powyżej 75):** W tym zakresie krzywa stabilizuje się i zaczyna łagodnie opadać. Nadmierne zwiększenie promienia skutkuje włączaniem do analizy komórek znacznie oddalonych od ogniska pierwotnego. Generuje to efekt rozcieńczenia sygnału - komórki niereagujące lub znajdujące się poza zasięgiem sygnału zaczynają dominować w zbiorze danych, maskując rzeczywiste interakcje.
3. **Optymalny przedział (45–60):** W celu uzyskania wiarygodnych wyników konieczne jest zbalansowanie przedziału. Wartości *Spatial Radius* między 45 a 60 stanowią optymalne okno analizy. Pozwalają one na wychwycenie realnej, lokalnej propagacji fal ERK, jednocześnie minimalizując wpływ szumu dla małych odległości, jak i efekt rozcieńczenia dla dużych dystansów.

2 Część B

2.1 Wprowadzenie

Analiza wzorców propagacji sygnału za pomocą algorytmu HDBSCAN

Kinaza ERK odpowiada za szlak sygnałowy MAPK/ERK, regulujący kluczowe procesy komórkowe. To, co próbujemy w tej pracy zrobić, to znaleźć za pomocą algorytmu HDBSCAN wzorce przechodzenia sygnału ERK między sąsiadującymi komórkami w formie łańcuchów w czasie, bazując na grafowych reprezentacjach (ang. *snapshots*) utworzonych na podstawie diagramów Voronoia.

Analiza bazuje na łańcuchach zmian w proporcji stężenia ERK. Jeden łańcuch zawiera zmianę między krokami czasowymi:

$$T \rightarrow T + 1 \quad \text{dla} \quad T \in \{0, 1, 2, 3, 4\}$$

W ten sposób dążymy do wyodrębnienia wzorców, które - mamy nadzieję - zostaną wykryte przez algorytm HDBSCAN. Znajdzenie takich struktur pozwoli na lepsze zrozumienie i przewidywanie rozchodzenia się sygnału ERK między komórkami.

2.2 Dane

2.2.1 Krótki Opis Danych

Dane które zostały nam przekazane to 257 (w danych, rozdzielonych pod nazwą `Image_Metadata_T`) dwu-wymiarowych *snapshot*-ów (dalej nazywanymi **reprezentacjami**), każdy reprezentujący klatkę czasową wykonywaną co 5 minut, wraz z odpowiadającymi jej `track_id` - czyli unikalnymi identyfikatorami danej komórki w **reprezentacji**.

2.2.2 Opis Zmiennych


Każda **reprezentacja** zawiera:

- `Nuclear_size` - Wielkość Jądra Komórkowego.
- `ERKTR_ratio` - Stosunek stężenia Kinazy ERK.
- `FoxO3A_ratio` - Stosunek stężenia Czynnika Transkrypcyjnego FOXO3A.
- `objNuclei_Location_Center_X` - Współrzędna X Jądra Komórkowego.
- `objNuclei_Location_Center_Y` - Współrzędna Y Jądra Komórkowego.


2.2.3 Zmienne użyte na rzecz Analizy

Na rzecz analizy, ze względu na rozmiar wygenerowanych danych, została użyta tylko zmiana `ERKTR_ratio` (Dalej **ERK**).

Nie mniej, część innych zmiennych została poddana częściowej obróbce razem z **ERK**, choć ostatecznie tylko ERK zostało użyte w algorytmie klastrującym.



Rysunek 6: Histogram dla Stosunków Stężeń przed i po skalowaniu




Rysunek 7: Wykresy pierwszych 5-ciu `track_id` przed i po skalowaniu


2.3 Metody

Po krótkce zostały użyte następujące metody:

1. MinMaxScaler - Dane zostały zeskaleowane niezależnie względem `track_id` w czasie.
2. Graf Vornoja - Na jego podstawie stwierdzamy sąsiedztwo poszczególnych `track_id` (czyli komórek).
3. Graf Reprezentacji - 257 grafów, każdy odpowiadający `Image_Metadata_T`, wierzchołki to `track_id`, połączone krawędziami na podstawie grafu Voronoja.
4. Łańcuchy Czasowe - Wybrane łańcuchy zmiany stężenia **ERK** długości 5, zawierające dla kolejnych przejść między `Image_Metadata_T`, zmianę stężenia **ERK**.. Zostają wybrane łańcuchy których odchylenie standardowe jest największe w liczbie 5.
5. Klastrowanie - Został Użyty algorytm HDBSCAN.




Rysunek 8: Rozłożenie poszczególnych wartości Łańcuchów



Rysunek 9: Rozłożenie poszczególnych wartości Łańcuchów

2.4 Wyniki



Rysunek 10: Rozłożenie poszczególnych wartości Łańcuchów na labele


Jeśli chodzi o wyniki to uzyskaliśmy 28 labeli + szum, gdzie stanowi on 75.72% labeli. Zbadaliśmy wyniki dwoma metrykami. Są to kolejno:

- **Davies-Bouldin Score:** 0.665
- **Calinski-Harabasz Score:** 68366.996


2.5 Dyskusja i interpretacja

Ostatecznie, udało się znaleźć wzorce w danych pokazujące standardowe oscylacje (czyli nie wzburzone ekspresje **ERK** w więcej niż 1 komórce) w łańcuchach długości 5.

Nie jest to to, co chcieliśmy znaleźć, jednak wyniki te są nadal bardzo satysfakcjonujące, biorąc pod uwagę to że bazując na nich, możemy odsiać labele które są niewzburzone (niewzburzone w więcej niż 1 komórce) i przebadać szum (który powinien zawierać te wzburzone w więcej niż 1 komórce) z innymi parametrami algorytmu klastrującego.



Rysunek 11: Rozłożenie poszczególnych wartości Łańcuchów na labele



Rysunek 12: Rozłożenie poszczególnych wartości Łańcuchów na labele